

The Maximum Likelihood estimation.

Sea  $A(x_1, \dots, x_n)$  un vector aleatorio cuya distribución depende de un parámetro  $\theta$

Definimos la función de verosimilitud de  $A$  es:

$$L(\theta) = f_{x_1, \dots, x_n}(x_1, \dots, x_n; \theta)$$

Que es la función de densidad evaluada en el Vector  $A$  es una función del parámetro. No necesariamente son idénticamente distribuidas.

Cuando son independientes

$$\begin{aligned} L(\theta) &= f(x_1; \theta) f(x_2; \theta) \dots f(x_n; \theta) \\ &= \prod_{i=1}^n f(x_i; \theta) \end{aligned}$$

El método consiste en maximizar la función  $L(\theta)$ .  $\theta$  que maximiza  $L(\theta)$  se conoce como estimación máxima verosímil

"Dicho Valor  $\theta$  maximiza la probabilidad que el modelo describe a  $A$ "

Sea  $A(x_1, \dots, x_n) \propto \exp(\alpha)$

$$\Rightarrow L(\theta) = \prod_{i=1}^n \frac{e^{-x_i/\alpha}}{\alpha} = \frac{1}{\alpha^n} e^{-\sum x_i/\alpha}$$

Tomamos Logaritmo natural. (Dado que  $\ln(x)$  monótono)

$$\ln L(\theta) = \ln \left( \left(\frac{1}{\alpha}\right)^n e^{-\sum x_i/\alpha} \right)$$

$$= n \ln \left( \frac{1}{\alpha} \right) - \sum \frac{x_i}{\alpha}$$

Para encontrar el máximo encontremos el máximo

$$\frac{d \ln L(\theta)}{d \alpha} = n \frac{1}{\alpha} \left( -\frac{1}{\alpha^2} \right) - \left( -\frac{1}{\alpha^2} \right) \sum x_i = 0$$

$$\alpha = \frac{\sum x_i}{n} \quad \text{promedio muestral } \bar{x}$$

Se acostumbra a notar

$$\hat{\alpha} = \bar{x}$$

---

Ejemplo 2 Normal Sea  $A(x_1, \dots, x_n)$  con  $A \sim N(\mu, \sigma^2)$

La función de Verosimilitud es:

$$L(\mu, \sigma^2) = f(x_1; \mu, \sigma^2) \dots f(x_n; \mu, \sigma^2)$$

$$= \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x_1-\mu)^2}{2\sigma^2}} \cdots \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x_n-\mu)^2}{2\sigma^2}}$$

$$= (2\pi\sigma^2)^{-n/2} \cdot \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2\right)$$

Tomando Logaritmos.

$$\ln L(\mu, \sigma^2) = -\frac{n}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2$$

Ahora puntos críticos:

$$\frac{\partial \ln L(\mu, \sigma^2)}{\partial \mu} = \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu) \quad \frac{\partial \ln L(\mu, \sigma^2)}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{1}{2(\sigma^2)^2} \sum_{i=1}^n (x_i - \mu)^2$$

$$\Rightarrow \sum_{i=1}^n (x_i - \mu) = 0 \quad \text{y} \quad -n\sigma^2 + \sum_{i=1}^n (x_i - \mu)^2 = 0 \quad (2)$$

Resolver sistema de ecuaciones

$$\text{De (1)} \quad \hat{\mu} = \bar{x} \quad \text{de (2)} \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

Ejercicio Calcular la Matriz Hessiana y Mostrar que es definida Negativa:

$$H(\mu, \sigma^2) = \begin{pmatrix} \frac{\partial^2 \ln L(\mu, \sigma^2)}{\partial \mu^2} & \frac{\partial^2 \ln L(\mu, \sigma^2)}{\partial \mu \partial \sigma^2} \\ \frac{\partial^2 \ln L(\mu, \sigma^2)}{\partial \sigma^2 \partial \mu} & \frac{\partial^2 \ln L(\mu, \sigma^2)}{\partial \sigma^4} \end{pmatrix}$$



$$\begin{pmatrix} -\frac{1}{\sigma^2} & -(\sigma^2)^{-2} \sum_{i=1}^n (x_i - \mu) \\ -(\sigma^2)^{-2} \sum_{i=1}^n (x_i - \mu) & \frac{n}{2}(\sigma^2)^{-2} - (\sigma^2)^{-3} \sum_{i=1}^n (x_i - \mu)^2 \end{pmatrix}$$

Evaluar en el punto crítico

$$H(\hat{\mu}, \hat{\sigma}^2) = \begin{pmatrix} -n(\hat{\sigma}^2)^{-1} & 0 \\ 0 & -\frac{n}{2}(\hat{\sigma}^2)^{-2} \end{pmatrix}$$

Como  $H_{11} < 0$  y el determinante  $|H(\hat{\mu}, \hat{\sigma}^2)| > 0$

Ejemplo 3 Poisson

$$\frac{e^{-\lambda} \lambda^x}{x!} \quad \lambda = \theta$$

$$L(\theta) = \prod_{i=1}^n \frac{e^{-\theta} \theta^{x_i}}{x_i!} = \frac{e^{-n\theta} \theta^{\sum x_i}}{\prod_{i=1}^n x_i!}$$

Tomando Logaritmos

$$\ell(\theta) = \ln L(\theta) = -n\theta + \sum x_i \ln \theta - \ln \prod_{i=1}^n x_i!$$

Derivando

$$\frac{\partial \ell(\theta)}{\partial \theta} = -n + \frac{\sum x_i}{\theta} = 0$$

$$\Rightarrow \hat{\theta} = \frac{\sum x_i}{n} = \bar{X} \quad \text{Media muestral.}$$

Varianza de estimadores

$$V(\hat{\theta}) = E(\hat{\theta}^2) - E(\hat{\theta})^2 \quad \text{No calculable en general}$$

Para la exponencial

$$\begin{aligned} & \int \dots \int \left( \frac{1}{n} \sum_{i=1}^n x_i \right)^2 \frac{1}{\theta} e^{-x_1/\theta} \dots \frac{1}{\theta} e^{-x_n/\theta} dx_1 \dots dx_n \\ & - \left( \int \dots \int \left( \frac{1}{n} \sum_{i=1}^n x_i \right) \frac{1}{\theta} e^{-x_1/\theta} \dots \frac{1}{\theta} e^{-x_n/\theta} dx_1 \dots dx_n \right)^2 \\ & = \frac{\theta^2}{n} \end{aligned}$$


Expandiendo alrededor del Estimador

$$\log L(\theta) = \log L(\hat{\theta}) + \frac{\partial \log L}{\partial \theta} \Big|_{\theta=\hat{\theta}} (\theta - \hat{\theta}) + \frac{1}{2!} \left( \frac{\partial^2 \log L}{\partial \theta^2} \Big|_{\theta=\hat{\theta}} \right) (\theta - \hat{\theta})^2$$

$$\log L(\theta) = \log \max - \frac{(\theta - \hat{\theta})^2}{2\hat{\sigma}_\theta^2}$$

Si Evaluamos en  $\theta = \hat{\theta} \pm \hat{\sigma}_\theta$

$$\log L(\hat{\theta} \pm \hat{\sigma}_\theta) = \log \max - \frac{(\hat{\theta} \pm \hat{\sigma}_\theta - \hat{\theta})^2}{2\hat{\sigma}_\theta^2}$$



$$= \log \max - \frac{1}{2} \Rightarrow \hat{\sigma}_\theta^2 = - \frac{1}{\frac{\partial^2 \log L}{\partial \theta^2} \Big|_{\theta=\hat{\theta}}}$$